

情報工学科 講義 デジタル信号処理B (2025/06/19)

第3回 (Aからカウントして第10回) ベクトル・行列微分の基礎と応用

情報工学科 准教授 高道 慎之介



Takamichi Laboratory
慶應義塾大学 高道研究室

イントロダクション (日程以外はデジタル信号処理 A と同じ)

ディジタル信号処理Bの授業予定 (仮)

第XX回	日付	内容 (順次変わっていくので予想)	
第01回	2025/05/29	適応信号処理, 信号処理	昨年のBの途中まで
第02回	2025/06/12	ベクトル・行列微分の基礎と応用	
第03回	2025/06/19	(次回以降にアナウンス)	新規内容
第04回	2025/06/26		
第05回	2025/07/03		
第06回	2025/07/10		
第07回	2025/07/17	総合演習. 期末試験の練習としての立ち位置.	
期末試験	2025/07/??	(日程は後日アナウンス)	

前々回の演習課題

演習

以下の問題について、その過程も含めて回答せよ。回答は PDF or DOCX 形式とする。手書き or PC利用は問わない。


1. $x(n) = \sin\left(\frac{\pi}{4}(n-1)\right)$, $N = 8$ における自己相関関数を計算せよ。関数の値が大きくなるのは、信号の周期に一致する時刻であることを確認せよ。
2. $x(n) = \sin\left(\frac{\pi}{4}(n-1)\right)$, $y(n) = \cos\left(\frac{\pi}{4}(n-1)\right)$, $N = 8$ における相互相関関数を計算せよ。関数の値が大きくなるのは、信号の時刻ずれ $\left(-\frac{\pi}{2} \text{ or } \frac{3\pi}{2}\right)$ に一致する時刻であることを確認せよ。

解説

- 解き方 1 : 数値表を書く (授業でやったやつ)
 - 片方の信号の時刻をずらして要素ごとに積 $\rightarrow$ 総和
 - 時刻ずらしが {信号自身の周期, 信号同士の時刻ずれ} に一致したとき, 相関関数の値が大きくなる
- 解き方 2 : 一般項を求める
 - 結局 $\sin$ と $\sin$ の積, あるいは $\sin$ と $\cos$ の積なので加法定理を使えば一般項が求まる.

前回の演習課題

演習



声帯とは、喋ったときに喉が震える部分である。「あー」としゃべったときに喉に手を当てると分かる。声道とは、喉や口のような、空気の通り道を指す。声帯で作られる音（音源信号）を x ，声道のインパルス応答を h とすると、出力される音声は $y = h * x$ ($*$ は畳み込み) で計算することができる。

[] # 課題: <https://www.slideshare.net/akinoriito549/phonetics-23821542> の p.24 に、
日本語母音の第一フォルマント(F1), 第二フォルマント(F2) の図がある。
これを参考に formant_hz の値を変更し、/a/ 以外の母音を合成できることを確認しよう。
また、基本周波数 f0_hz がかわると、声の高さが変わることも確認しよう。

解説

- フォルマント周波数
 - (ざっくり言えば) IIRフィルタの極で増幅される周波数
- 次数4 の IIR フィルタを構成し極を変化させることで、聞こえる母音 (a, i, u, e, o) が変わる.

本日の内容

復習：ノイズキャンセリング



復習：数式で表すと

フォワード計算

$$y[n] = \sum_{k=0}^{N-1} \underline{w_k[n]} x[n-k]$$

最小化したい目的関数


$$\underline{e^2[n]} = (d[n] - y[n])^2 = \left(d[n] - \sum_{k=0}^{N-1} w_k[n] x[n-k] \right)^2$$

目的関数の値を最小化するようにフィルタ係数を求めたい


漏れる雑音を打ち消す音

ノイズキャンセラ


デジタル回路



内部に漏れる雑音（経路や特性は未知かつ時変）



前のページの式はこのように見ることができる



ベクトルで微分すべきなのは？
ベクトルで微分するって何？

本日の内容

- 今まで習った「スカラー値関数をスカラーで微分する」を拡張する

信号処理だけでなく，最適化や深層学習にも関連するので理解しておこう

復習：スカラー値関数をスカラーで微分する

スカラを引数にとるスカラ値関数

変数の形



$x \in \mathbb{R}$

$f(\cdot)$



$y \in \mathbb{R}$

- 関数の例と微分を考える
- 例 1 : $f(x) = x^2$
 - その微分 : $f'(x) = 2x$
 - $x > 0$ で $f'(x) > 0$ (右に向かって増), $x = 0$ で $f'(x) = 0$ (最小値)
- 例 2 : $f(x) = \sin(x)$
 - その微分 : $f'(x) = \cos(x)$
 - 変化率が周期的に変化. 極小値・極大値が周期的に出現.

接線の傾き

例えば勾配法（最急降下法など）に使う



で見えて理解する

「勾配法」


$$x_{new} = x_{old} - \alpha \frac{\partial y}{\partial x}$$

ThothChildren

4min

スカラ値関数をベクトルで微分する

ベクトルを引数にとるスカラー値関数

基本的に列ベクトル




- 関数の例を考える

- 例： $f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}$

- 書き換えると $f(\mathbf{x}) = \sum_i a_i x_i$
- この微分は？

余談：決定論的信号処理と統計的信号処理

- **決定論的**信号処理 ← この講義は基本的にこれ
 - 入力とシステムが決まれば、出力を一意に決定できる信号処理
 - 例えば、授業でやった FIR, IIR フィルタ
- **統計的**信号処理 ← この講義では扱わない
 - 不確実性を伴って観測される信号を扱う処理
 - 例えば，
 - 教室にスピーカとマイクを置いて2回収録しても、同じ信号にはならない
 - 同じ被写体をカメラで2回写しても、同じ画像にはならない
 - 統計的信号処理では、信号の従う**確率分布**を考える
 - 白色雑音 (ガウス雑音, ガウスノイズ) もその一つ
 - 変数が2つ以上ある場合、ベクトルに対する確率変数を考える
 - 例えば、16点DFTを実行して、ナイキスト周波数までにあたる9個の周波数の振幅スペクトルについて、確率変数を考える場合



ベクトルのための正規分布

- 単変量正規分布 (確率変数がスカラー)

$$p(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

確率変数 $\downarrow$ 分散
平均

これらも「ベクトルを引数にとるスカラー関数」にあたる

- 多変量正規分布 (確率変数がベクトル)

$$p(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

d
確率変数ベクトル $\downarrow$ 共分散行列
平均ベクトル

共分散行列
(4次元変数の場合)

←ある次元同士の共分散

←ある次元の分散

スカラー値関数をベクトルで微分する：その定義

- 定義：スカラー値関数をベクトルで微分するとベクトルになる

$$\frac{\partial f}{\partial \mathbf{x}} = \left[\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_d} \right]^\top$$

各次元の偏微分

- 例えば以下のように計算される．公式として覚えておくと楽．

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}$$

$$\frac{\partial f}{\partial x_i} = a_i \longrightarrow \frac{\partial f}{\partial \mathbf{x}} = \mathbf{a}$$

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x}$$

$$\frac{\partial f}{\partial x_i} = \frac{\partial}{\partial x_i} \sum_{j=1}^d x_j^2 = 2x_i \longrightarrow \frac{\partial f}{\partial \mathbf{x}} = 2\mathbf{x}$$

演習：以下の関数 $f()$ について $\frac{\partial f}{\partial \mathbf{x}}$ を求めよ

1. $f(\mathbf{x}) = x_1^2 + 3x_2 \quad \mathbf{x} = [x_1, x_2]^\top$

2. $f(\mathbf{x}) = (\mathbf{a}^\top \mathbf{x})^2$

3. $f(\mathbf{x}) = \|\mathbf{x} - \mathbf{b}\|^2$

スカラー値関数を行列で微分する

行列を引数にとるスカラー値関数



- 例 1 : トレース関数

A diagram illustrating the trace function $f(\mathbf{X}) = \text{tr}(\mathbf{A}^T \mathbf{X})$. The input $\mathbf{X}$ is a blue square. The output $f(\mathbf{X})$ is a small blue square. The matrix $\mathbf{A}^T$ is represented by a blue square, and $\mathbf{X}$ is represented by a blue square.

$$f(\mathbf{X}) = \text{tr}(\mathbf{A}^T \mathbf{X})$$

- 例 2 : ノルム平方

A diagram illustrating the squared norm function $f(\mathbf{X}) = (\mathbf{X}\mathbf{w} - \mathbf{a})^T (\mathbf{X}\mathbf{w} - \mathbf{a})$. The input $\mathbf{X}$ is a blue square. The output $f(\mathbf{X})$ is a small blue square. The vector $\mathbf{w}$ is represented by a blue vertical rectangle, and the vector $\mathbf{a}$ is represented by a blue vertical rectangle.

$$f(\mathbf{X}) = (\mathbf{X}\mathbf{w} - \mathbf{a})^T (\mathbf{X}\mathbf{w} - \mathbf{a})$$

スカラー関数を行列で微分する：その定義

- 定義：スカラー関数を行列で微分すると行列になる

$$\frac{\partial f}{\partial \mathbf{X}} = \left[\frac{\partial f}{\partial x_{ij}} \right]_{ij}$$

行列の i, j 番目の要素

- 例えば以下のように計算される．公式として覚えておくと楽．

$$f(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X}) \longrightarrow f(\mathbf{X}) = \sum_p \sum_q A_{pq} X_{pq} \longrightarrow \frac{\partial f}{\partial X_{ij}} = A_{ij}$$

$\mathbf{A}$ が転置行列なので添字注意

$p=i, q=j$ になるときのみ

$$\frac{\partial f}{\partial \mathbf{X}} = \mathbf{A}$$


演習：以下の公式を証明せよ．

$$f(\mathbf{X}) = \text{tr}(\mathbf{X}\mathbf{A}\mathbf{X}^\top) \longrightarrow \frac{\partial f}{\partial \mathbf{X}} = \mathbf{X}\mathbf{A}^\top + \mathbf{X}\mathbf{A}$$



正方行列

- まず $f()$ をスカラの式で表現してみよう



- $\frac{\partial f}{\partial X_{ij}}$ を計算しよう．総和のうち特定の項だけが X_{ij} に依存する．それを微分すると，答えの式が見えてくるはず．

演習：以下の公式を証明せよ.

$$f(\mathbf{X}) = \text{tr}(\mathbf{X} \mathbf{A} \mathbf{X}^\top) \qquad \frac{\partial f}{\partial \mathbf{X}} = 2\mathbf{X} \mathbf{A}$$

対称行列

- 前のページの結果をうまく使おう

公式

関数 $f(\mathbf{X})$	微分 $\frac{\partial f}{\partial \mathbf{X}}$
$\text{tr}(\mathbf{A}^\top \mathbf{X})$	$\mathbf{A}$
$\text{tr}(\mathbf{A} \mathbf{X})$	$\mathbf{A}^\top$
$\text{tr}(\mathbf{X} \mathbf{A} \mathbf{X}^\top)$	$\mathbf{X} \mathbf{A}^\top + \mathbf{X} \mathbf{A}$
$\text{tr}(\mathbf{X} \mathbf{A} \mathbf{X}^\top)$ ($\mathbf{A}$ が対称行列)	$2\mathbf{X} \mathbf{A}$
$(\mathbf{X} \mathbf{w} - \mathbf{a})^\top (\mathbf{X} \mathbf{w} - \mathbf{a})$	$2(\mathbf{X} \mathbf{w} - \mathbf{a}) \mathbf{w}^\top$

関数に $\text{tr}()$ を付けて (スカラーなので等価), $\text{tr}()$ の中身を展開. まとめると, 表の公式を使って導出可能

ベクトル値関数をベクトルで微分する

ベクトルを引数にとるベクトル値関数



- 例えば

$$\mathbf{f}(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}$$

A diagram illustrating the dimensions of the variables in the equation $\mathbf{f}(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}$. $\mathbf{f}(\mathbf{x})$ is represented by a blue vertical rectangle, $\mathbf{A}$ by a blue horizontal rectangle, $\mathbf{x}$ by a blue vertical rectangle, and $\mathbf{b}$ by a blue vertical rectangle.

深層学習における線形層

- その微分は行列 (ヤコビ行列, ヤコビアン) になる

A diagram showing the dimensions of the variables in the Jacobian equation. $\frac{\partial \mathbf{f}}{\partial \mathbf{x}}$ is represented by a blue vertical rectangle, and the Jacobian matrix $\left[\frac{\partial f_i}{\partial x_j} \right]_{ij}$ is represented by a blue horizontal rectangle.

$$\frac{\partial \mathbf{f}}{\partial \mathbf{x}} = \left[\frac{\partial f_i}{\partial x_j} \right]_{ij}$$

出力側が列，入力側が行になるので注意.
(スカラー値ベクトルのときは，入力側が列)

例えば

- 前ページの例なら

$$\mathbf{x} \in \mathbb{R}^N \longrightarrow \mathbf{f}(\mathbf{x}) = \mathbf{Ax} + \mathbf{b} \longrightarrow \mathbf{y} \in \mathbb{R}^M$$

$$\frac{\partial \mathbf{f}}{\partial \mathbf{x}} = \mathbf{A}$$

- 連鎖律 (chain rule) も同様に適用可能
 - 信号処理システムを連結する．ニューラルネットワークを連結する

$$\mathbf{x} \in \mathbb{R}^N \longrightarrow \mathbf{f}(\mathbf{x}) = \mathbf{Ax} + \mathbf{b} \longrightarrow \mathbf{y} \in \mathbb{R}^M \longrightarrow \mathbf{g}(\mathbf{y}) = \mathbf{Cy} + \mathbf{d} \longrightarrow \mathbf{z} \in \mathbb{R}^L$$

$$\frac{\partial \mathbf{g}}{\partial \mathbf{x}} = \frac{\partial \mathbf{g}}{\partial \mathbf{y}} \frac{\partial \mathbf{f}}{\partial \mathbf{x}} = \mathbf{CA}$$

まとめ
(matome)

まとめ

- スカラ値関数を
 - スカラで微分する → スカラ
 - ベクトルで微分する → ベクトル
 - 行列で微分する → 行列
- ベクトル値関数を
 - ベクトルで微分する → 行列

課題 (exercise)

演習

関数 $f(\mathbf{X})$	微分 $\frac{\partial f}{\partial \mathbf{X}}$
$\text{tr}(\mathbf{A}^\top \mathbf{X})$	$\mathbf{A}$ (1) これを証明せよ
$\text{tr}(\mathbf{A}\mathbf{X})$	$\mathbf{A}^\top$
$\text{tr}(\mathbf{X}\mathbf{A}\mathbf{X}^\top)$	$\mathbf{X}\mathbf{A}^\top + \mathbf{X}\mathbf{A}$
$\text{tr}(\mathbf{X}\mathbf{A}\mathbf{X}^\top)$ ($\mathbf{A}$ が対称行列)	$2\mathbf{X}\mathbf{A}$ (2) これを証明せよ
$(\mathbf{X}\mathbf{w} - \mathbf{a})^\top (\mathbf{X}\mathbf{w} - \mathbf{a})$	$2(\mathbf{X}\mathbf{w} - \mathbf{a})\mathbf{w}^\top$